AI Safety Challenge

Çıktı: AI F

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Makine otomatik onay vermemeli, kusurlu testereyi ayırmalı ve operatörün manuel kontrolünü istemelidir. Güvenlik açısından kritik durumlarda işlem güvenli şekilde durdurulmalıdır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Görüntü kalitesi ve veri tutarlılığı kontrol edilir. Şüpheli görüntü algılanırsa otomatik karar devre dışı bırakılır ve operatöre uyarı verilir.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Örnek güven eşiği %90 seçilir. Bu değerin altında otomatik onay verilmez; sistem güvenli moda geçer ve operatör kontrolü ister.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Otomatik onay engellenir, insan kontrolü istenir.
Girdi manipüle edildi	Şüpheli veri reddedilir, otomatik işlem durdurulur.
Confidence düştü	%90 altında manuel kontrol ve güvenli mod uygulanır.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.